

Market Research — Dedicated Inference (GPU Reserved, Always-On)

1. Executive Summary
 2. Dedicated Inference là gì?
 - 2.1 Định nghĩa & Định vị
 - 2.2 Dedicated vs Serverless — So sánh
 - 2.3 Khi nào chọn Dedicated (so với Serverless)
 3. Thị trường toàn cầu
 - 3.1 Quy mô & tăng trưởng
 - 3.2 Xu hướng quan trọng cho Dedicated
 4. Thị trường Việt Nam
 5. Bối cảnh cạnh tranh — Dedicated Inference
 - 5.1 Đối thủ chính (dedicated / reserved GPU)
 - 5.2 Đối thủ khu vực
 - 5.3 Định vị FPT DDI
 6. Pricing Benchmark (Dedicated GPU/giờ, 2026)
 7. Phân khúc khách hàng mục tiêu
 8. SWOT
 - Strengths
 - Weaknesses
 - Opportunities
 - Threats
 9. Chiến lược Go-To-Market
 - 9.1 Định vị sản phẩm (Positioning Statement)
 - 9.2 Chiến lược giá
 - 9.3 Kênh phân phối
 10. Lộ trình đề xuất (Roadmap)
 11. KPI & Success Metrics
 12. Khuyến nghị tổng hợp
 - Must (bắt buộc)
 - Should (nên)
 - Could (có thể)
 - Won't (không làm ngay)
 13. Top đối thủ cần theo dõi sát
- PHỤ LỤC — Nguồn dữ liệu

Market Research — Dedicated Inference (GPU Reserved, Always-On)

Phiên bản: 1.0 **Ngày:** 18/08/2026 **Trạng thái:** Draft **Chủ sở hữu:** Thuan Luu Thi (PO) **Phạm vi:** Nghiên cứu thị trường cho mô hình **Dedicated Inference** — deploy model trên GPU dedicated/reserved, always-on, không shared capacity, không rate limits, phù hợp traffic nghiêm túc hơn serverless. **Định vị sản phẩm:** > “Deploy an AI

model running on dedicated, reserved GPUs. Always on, no shared capacity, and no rate limits. Better suited for serious traffic than serverless.”

Liên quan: docs/market-research-fpt-ddi.md, docs/srs-ddi-my-endpoints.md, docs/competitive-analysis-ddi-gpu-container-k8s-vm.md, docs/technical-note-a30-model-serving.md

1. Executive Summary

Câu hỏi	Trả lời
Sản phẩm là gì?	Dedicated Inference: deploy model trên GPU dedicated/reserved , always-on, không shared capacity, không rate limits
Khác serverless thế nào?	Serverless = chia sẻ hạ tầng, pay-per-token, có cold-start & rate limits. Dedicated = tài nguyên riêng, trả theo GPU/giờ, hiệu năng ổn định
Phù hợp ai?	Traffic nghiêm túc (production, enterprise), latency ổn định, bảo mật tách biệt, workload dự đoán được
Thị trường	AI inference toàn cầu ~\$117,8 tỷ (2026), GPU ~35,3%; cloud là phân khúc tăng nhanh nhất
Đối thủ	Together AI, Fireworks, Baseten, Lambda, RunPod, CoreWeave, Replicate, DeepInfra
Cơ hội FPT	“Dedicated + data residency VN + tiếng Việt” — khoảng trống chưa ai chiếm
Khuyến nghị	Định vị dedicated cho enterprise/production, pricing theo GPU/giờ (neo-cloud), highlight always-on + không rate limits

2. Dedicated Inference là gì?

2.1 Định nghĩa & Định vị

Dedicated Inference là mô hình deploy model trên **GPU được cấp phát riêng (dedicated/reserved)** cho một khách hàng/tenant duy nhất. Tài nguyên GPU **always-on** (luôn sẵn sàng), **không chia sẻ capacity** với tenant khác, và **không có rate limits** — trái ngược với serverless (chia sẻ hạ tầng, có giới hạn).

2.2 Dedicated vs Serverless — So sánh

Tiêu chí	Dedicated (FPT DDI)	Serverless
Tài nguyên GPU	× Riêng (reserved, không chia sẻ)	Chia sẻ (shared pool)
Trạng thái	Always-on	Scale-to-zero / cold-start
Rate limits	Không có	Có
Hiệu năng	Ổn định, dự đoán được	Dao động theo load
Latency	Thấp, nhất quán	▲ Có thể tăng khi cold-start
Định giá	GPU/giờ (reserved)	Pay-per-token
Bảo mật tách biệt	Hoàn toàn	Chia sẻ hạ tầng
Phù hợp	Traffic nghiêm túc, production, enterprise	Traffic thưa, spike, prototype
Tối ưu chi phí	Workload liên tục, tải cao	Workload không thường xuyên

2.3 Khi nào chọn Dedicated (so với Serverless)

Tình huống	Chọn Dedicated	Chọn Serverless
Traffic ổn định, cao, liên tục	■	
Yêu cầu latency nhất quán (production)	■	
Bảo mật tách biệt, data residency	■	
Không chấp nhận rate limits	■	

Tình huống	Chọn Dedicated	Chọn Serverless
Workload spike không dự đoán được		
Prototype / thử nghiệm		
Chi phí thấp cho tải thấp		
Nguyên tắc: Dedicated = dành cho “serious traffic” — workload sản xuất cần hiệu năng ổn định, bảo mật và không giới hạn. Serverless phù hợp workload thừa/không dự đoán được.		

3. Thị trường toàn cầu

3.1 Quy mô & tăng trưởng

Chỉ số	Giá trị	Nguồn
AI inference toàn cầu	~\$117,8 tỷ (2026)	Fortune Business Insights
Phân khúc GPU	~35,3% thị phần AI inference	Fortune Business Insights
AI data center GPU	\$12,83 tỷ (2026) → \$77,15 tỷ (2035), CAGR ~22%	Precedence Research
Cloud deployment	Phân khúc tăng trưởng nhanh nhất (2026-2035)	SNS Insider
Tổng chi tiêu AI	~\$2,52 nghìn tỷ (2026)	—

3.2 Xu hướng quan trọng cho Dedicated

- Serverless → Dedicated migration:** khi workload ổn định, khách hàng chuyển từ serverless sang dedicated để tối ưu chi phí & hiệu năng — **đây là động lực chính cho DDI**
- Break-even self-hosting:** ~2M tokens/ngày hoặc GPU utilization 22-48% → dedicated khả thi về kinh tế
- Enterprise ưu tiên data residency & compliance:** tài chính, y tế, chính phủ cần hạ tầng riêng
- OpenAI-compatible API thành chuẩn:** giảm chi phí chuyển đổi từ serverless sang dedicated
- GPU thế hệ mới (Blackwell):** B200/B300 tăng hiệu năng, nhưng nguồn cung hạn chế → cơ hội cho ai có sớm

4. Thị trường Việt Nam

Chỉ số	Giá trị	Nguồn
AI Việt Nam	~\$1 tỷ (2026); CAGR ~39% đến 2031	Statista
Cloud & data center	~\$1,5 tỷ (2026)	—
Doanh nghiệp dùng AI	93%	—
Chiến lược quốc gia	250.000 GPU, 6% GDP, 500K chuyên gia (2030)	—
FPT × NVIDIA	\$200M AI Factory, 43 dịch vụ cloud AI, NVIDIA đầu tư \$4-4,5 tỷ	—

Insight: Doanh nghiệp Việt Nam (ngân hàng, tài chính, chính phủ) có nhu cầu **data residency + dedicated** rất cao do quy định (Nghị định 13/2023) — đây là phân khúc khách hàng chính của DDI.

5. Bối cảnh cạnh tranh — Dedicated Inference

5.1 Đối thủ chính (dedicated / reserved GPU)


Provider	Mô hình Dedicated	Pricing GPU/giờ (tham chiếu)	Điểm mạnh
Together AI	GPU Clusters (reserved), Dedicated Container Inference	H100 ~\$2-3	Container + k8s + VM trọn gói
Fireworks AI	Dedicated deployments, Virtual Cloud, BYOC	B200 \$9	Engine tối ưu, BYOC
Baseten	Dedicated + serverless, cross-cloud autoscale	—	Autoscaling đa cloud
Lambda	1-Click Clusters, MK8s	B200 \$3,49	Giá rẻ, price transparency
RunPod	Dedicated GPU Pods	H100 \$2,89	Compute utility, linh hoạt

Provider	Mô hình Dedicated	Pricing GPU/giờ (tham chiếu)	Điểm mạnh
CoreWeave	Kubernetes-native, reserved	B200 reserved	Training + inference
Replicate	Custom model deployment	Per-second	Multi-modal, UX
DeepInfra	Serverless (chủ yếu)	Rẻ nhất	Không phải dedicated chính

5.2 Đối thủ khu vực

- **GreenNode (VN)**: hợp tác NVIDIA, GPU cloud tại VN — đối thủ nội địa trực tiếp
- **BytePlus (ByteDance)**: AI cloud, cạnh tranh SEA
- **Viettel**: hạ tầng cloud & AI tiềm năng

5.3 Định vị FPT DDI



Vị trí FPT: góc “**niche local dedicated**” — dedicated + data residency Việt Nam. Khoảng trống chưa đối thủ nào chiếm giữ mạnh.

6. Pricing Benchmark (Dedicated GPU/giờ, 2026)

GPU	Range on-demand	Provider thấp	Hyperscaler cao
H100	\$1,99 – \$14,90	Vast \$1,60 · GMI \$2,00 · RunPod \$2,89	AWS ~\$6,16
H200	\$1,99 – \$13,78	GMI \$2,60 · Jarvislabs \$3,99	AWS \$7,91 · Azure \$10,60

GPU	Range on-demand	Provider thấp	Hyperscaler cao
B200	\$3,20 - \$16,11	Runcrate \$3,20 · Lambda \$3,49	AWS \$14,24 · GCP \$16,11
A30	Entry-level (thấp hơn H100 đáng kể)	—	—

Insights pricing: - **Neo-cloud (chuyên GPU)** định giá thấp hơn hyperscaler **40-60%** — FPT nên theo nhóm này - **Reserved/dedicated** rẻ hơn on-demand khi cam kết dài hạn - **A30** = entry-point giá rẻ thu hút SME, upsell lên H100/H200/B300

7. Phân khúc khách hàng mục tiêu

Phân khúc	Nhu cầu	Sản phẩm phù hợp	Ưu tiên
Enterprise VN (ngân hàng, tài chính, y tế, chính phủ)	Data residency, compliance, SLA, bảo mật tách biệt	Dedicated H100/H200 + SLA	Cao
Startup GenAI VN	Chi phí thấp, triển khai nhanh, không rate limits	A30/H100 dedicated	Cao
Enterprise Nhật/Hàn	Dedicated, latency thấp, hỗ trợ địa phương	Dedicated H200/B300	Trung
ISV / Agency	Tích hợp API, white-label, SLA	API + SDK	Trung
Dev / Research	Model catalog rộng	Serverless + dedicated	Thấp

8. SWOT

Strengths

- Hạ tầng tự chủ tại VN, quan hệ chiến lược NVIDIA (AI Factory H100/H200)
- **Data residency + compliance** — lợi thế độc nhất cho enterprise
- **Always-on, không rate limits** — phù hợp production traffic
- Model tiếng Việt FPT.AI, hiểu văn hóa địa phương

- Đa dạng GPU: A30 → H100 → H200 → B300

Weaknesses

- Brand awareness toàn cầu thấp hơn Together/Fireworks/Baseten
- Model catalog có thể hẹp hơn đối thủ
- Nguồn cung GPU thế hệ mới (B300) hạn chế
- Năng lực vận hành GPU quy mô lớn còn mới

Opportunities

- Thị trường inference ~\$117,8 tỷ, CAGR cao; cloud tăng nhanh nhất
- Xu hướng serverless → dedicated migration
- Chiến lược AI quốc gia VN (250K GPU, 6% GDP)
- Khoảng trống “dedicated + data residency VN” chưa ai chiếm
- NVIDIA đầu tư \$4-4,5 tỷ vào VN

Threats

- Đối thủ toàn cầu giàu funding (\$1,3-2 tỷ) mở rộng nhanh
- GreenNode/Viettel cạnh tranh nội địa
- Biến động giá GPU & nguồn cung
- Cuộc đua giảm giá inference làm giảm margin
- Phụ thuộc NVIDIA (chuỗi cung ứng, chính sách xuất khẩu)

9. Chiến lược Go-To-Market

9.1 Định vị sản phẩm (Positioning Statement)

“FPT DDI — Deploy an AI model running on dedicated, reserved GPUs. Always on, no shared capacity, and no rate limits. Better suited for serious traffic than serverless.”

Ba trụ cột khác biệt: 1. **Dedicated & Always-on** — tài nguyên GPU riêng, luôn sẵn sàng, không shared capacity, không rate limits 2. **Data residency Việt Nam** — dữ liệu nằm tại VN, tuân thủ Nghị định 13/2023 3. **Tiếng Việt & địa phương** — model FPT.AI, hỗ trợ bản địa, latency thấp

9.2 Chiến lược giá

GPU	Định giá đề xuất (dedicated/giờ)	So với thị trường
A30	Entry-point rẻ, thu hút SME	Cạnh tranh nhất
H100	Ngang neo-cloud (\$2-3/giờ)	Cạnh tranh
H200	Ngang GMI/Jarvislabs (\$2,6-4/giờ)	Cạnh tranh

GPU	Định giá đề xuất (dedicated/giờ)	So với thị trường
B300	Premium, reserved	Cao hơn, dành enterprise

Nguyên tắc: định giá theo **neo-cloud chuyên GPU** (thấp hơn hyperscaler 40-60%), **reserved dài hạn ưu đãi** để giữ chân enterprise. Highlight “no rate limits” như giá trị cộng thêm so với serverless.

9.3 Kênh phân phối

- **Trực tiếp:** đội sales enterprise FPT (ngân hàng, tài chính, chính phủ)
- **Đối tác:** NVIDIA ecosystem, ISV, agency, hệ sinh thái FPT Smart Cloud
- **Digital:** self-serve portal, model catalog, free trial, API playground
- **Khu vực:** Việt Nam (core) → Nhật Bản, Hàn Quốc (mở rộng)

10. Lộ trình đề xuất (Roadmap)

Giai đoạn	Trọng tâm	KPI chính
Phase 1 — Foundation (0-6 tháng)	Ra mắt dedicated trên H100/A30, model catalog cốt lõi, API chuẩn, portal self-serve	≥20 model, ≥10 khách hàng pilot
Phase 2 — Scale (6-12 tháng)	Thêm H200/B300, SLA cam kết, BYOM, enterprise onboarding, data residency cert	≥50 model, ≥50 khách hàng, 99,9% uptime
Phase 3 — Expansion (12-24 tháng)	Mở rộng Nhật/Hàn, multi-region, fine-tuning platform	≥100 model, ≥200 khách hàng

11. KPI & Success Metrics

Loại	Metric	Mục tiêu
Adoption	Số model trong catalog	≥20 → 50 → 100
Adoption	Số khách hàng dedicated active	≥10 → 50 → 200

Loại	Metric	Mục tiêu
Usage	GPU utilization trung bình	≥60%
Performance	Uptime SLA (always-on)	≥99,9%
Performance	Time-to-first-token / latency	Theo benchmark model
Revenue	Revenue từ dedicated	Milestone theo phase
Satisfaction	NPS / retention	NPS ≥40, retention ≥90%

12. Khuyến nghị tổng hợp

Must (bắt buộc)

1. **Định vị rõ “dedicated + always-on + data residency VN”** — khác biệt cốt lõi
2. **Cam kết “no shared capacity, no rate limits”** trong SLA — đúng định vị
3. **Hoàn thiện model catalog** với model tiếng Việt FPT làm điểm nhấn
4. **OpenAI-compatible API + SDK** — chuẩn ngành, giảm chi phí chuyển đổi từ serverless

Should (nên)

1. **Pricing theo neo-cloud** (thấp hơn hyperscaler 40-60%), reserved ưu đãi
2. **Portal self-serve + free trial** — giảm ma sát onboarding
3. **Tận dụng quan hệ NVIDIA** — ưu tiên nguồn cung H200/B300
4. **Enterprise compliance pack** — data residency, audit, region selection

Could (có thể)

1. **BYOM (bring-your-own-model)** — giá trị enterprise
2. **Fine-tuning platform** tích hợp — upsell từ inference
3. **Multi-region** (Nhật, Hàn) — mở rộng quốc tế

Won't (không làm ngay)

1. Không cạnh tranh giá rẻ nhất serverless commodity với DeepInfra — tập trung dedicated value

13. Top đối thủ cần theo dõi sát

1. **Lambda** — benchmark giá GPU/giờ rẻ nhất, dedicated capacity, price transparency
 2. **Fireworks AI** — benchmark dedicated inference + engine tối ưu + pricing B200
 3. **GreenNode (VN)** — đối thủ nội địa trực tiếp, cùng hợp tác NVIDIA
 4. **Together AI** — benchmark model catalog + dedicated container
 5. **Baseten** — benchmark serverless→dedicated transition
-

PHỤ LỤC — Nguồn dữ liệu

- Fortune Business Insights, Precedence Research, SNS Insider — market size (2026)
- Statista — AI market Việt Nam, cloud market
- Digital in Asia, Báo Đầu Tư, VnEconomy, Lao Động — thị trường AI/GPU cloud VN, FPT × NVIDIA
- FPT Software, FPT Cloud — AI Factory, NVIDIA partnership
- Traxcn, PitchBook — funding/valuation đối thủ
- GMI Cloud, RunPod, Lambda, Jarvislabs, Spheron, AWS/Azure/GCP — GPU pricing benchmark (2026)
- vLLM, Local AI Master, GigaGPU — VRAM requirements (A30 serving)

Lưu ý: Số liệu thị trường là ước tính từ nguồn công khai (2026), có thể thay đổi. Nên xác minh lại trước khi trình bày chính thức.