

FPT DDI — Dedicated Inference · Market Research Slides (Rút gọn)

SLIDE 1 — Cover

FPT DDI — Dedicated Inference

Market Research & Chiến lược cạnh tranh

SLIDE 2 — Executive Summary

SLIDE 3 — Dedicated vs Serverless

SLIDE 4 — Thị trường toàn cầu & Việt Nam

SLIDE 5 — Bối cảnh cạnh tranh

SLIDE 6 — Ma trận định vị

SLIDE 7 — Pricing Benchmark (Dedicated GPU/giờ, 2026)

SLIDE 8 — Phân khúc khách hàng & SWOT

SLIDE 9 — Chiến lược GTM

SLIDE 10 — Lộ trình (Roadmap)

SLIDE 11 — Khuyến nghị

SLIDE 12 — Closing / Thank you

Cảm ơn!

Ghi chú cho người dựng deck

FPT DDI — Dedicated Inference · Market Research Slides (Rút gọn)

Bộ slide: 12 slides · Ngôn ngữ: Tiếng Việt · Phong cách: Consulting
(FPT brand) **Chủ sở hữu:** Thuan Luu Thi (PO) **Ngày:** 18/08/2026

Nguồn: docs/market-research-dedicated-inference.md

SLIDE 1 — Cover

FPT DDI — Dedicated Inference

Market Research & Chiến lược cạnh tranh

Deploy an AI model running on dedicated, reserved GPUs.
Always on, no shared capacity, and no rate limits. Better suited
for serious traffic than serverless.

**FPT · Dedicated Inference · Model Catalog · GPU Container
(H100 · H200 · B300 · A30)**

SLIDE 2 – Executive Summary

Câu hỏi	Trả lời
Sản phẩm là gì?	Dedicated Inference: deploy model trên GPU dedicated/ reserved, always-on, không shared capacity, không rate limits
Khác serverless?	Serverless = chia sẻ hạ tầng, pay-per-token, cold-start & rate limits. Dedicated = tài nguyên riêng, GPU/giờ, hiệu năng ổn định
Phù hợp ai?	Traffic nghiêm túc (production, enterprise), latency ổn định, bảo mật tách biệt
Thị trường	AI inference ~\$117,8 tỷ (2026), GPU ~35,3%; VN ~\$1 tỷ, CAGR ~39%
Cơ hội FPT	“Dedicated + data residency VN + tiếng Việt” — khoảng trống chưa ai chiếm


Presenter notes: Mở đầu bằng câu hỏi “Vì sao dedicated thay vì serverless?” để dẫn dắt.

SLIDE 3 – Dedicated vs Serverless

Tiêu chí	Dedicated [*] (FPT DDI)	Serverless [■]
Tài nguyên GPU	Riêng (reserved)	Chia sẻ (shared pool)
Trạng thái	Always-on [■]	Cold-start [▲]
Rate limits	Không có	Có
Hiệu năng	Ổn định, dự đoán được	Dao động theo load
Định giá	GPU/giờ (reserved)	Pay-per-token
Bảo mật tách biệt	Hoàn toàn	Chia sẻ hạ tầng
Phù hợp	Serious traffic, production	Spike, prototype

Nguyên tắc: Dedicated = “serious traffic”. Serverless phù hợp workload thừa/không dự đoán được. Khi workload ổn định, khách hàng chuyển serverless → dedicated (động lực chính cho DDI).

SLIDE 4 – Thị trường toàn cầu & Việt Nam



Chỉ số	Toàn cầu	Việt Nam
Quy mô AI	~\$117,8 tỷ (2026)	~\$1 tỷ (2026)
Tăng trưởng	CAGR ~22% (GPU data center)	CAGR ~39% đến 2031
Doanh nghiệp dùng AI	—	93%
Chiến lược quốc gia	—	250K GPU, 6% GDP, 500K chuyên gia (2030)
FPT × NVIDIA	—	\$200M AI Factory, 43 dịch vụ cloud AI, NVIDIA đầu tư \$4-4,5 tỷ

Insight: Doanh nghiệp VN (ngân hàng, tài chính, chính phủ) có nhu cầu **data residency + dedicated** rất cao do Nghị định 13/2023.


SLIDE 5 – Bối cảnh cạnh tranh

Provider	Mô hình Dedicated	Pricing GPU/giờ (tham chiếu)	Điểm mạnh
Together AI	GPU Clusters, Dedicated Container Inference	H100 ~\$2-3	Container + k8s + VM trọn gói
Fireworks AI	Dedicated deployments, Virtual Cloud, BYOC	B200 \$9	Engine tối ưu, BYOC
Baseten	Dedicated + serverless, cross-cloud autoscale	—	Autoscaling đa cloud
Lambda	1-Click Clusters, MK8s	B200 \$3,49	Giá rẻ, price transparency

Provider	Mô hình Dedicated	Pricing GPU/giờ (tham chiếu)	Điểm mạnh
RunPod	Dedicated GPU Pods	H100 \$2,89	Compute utility, linh hoạt
GreenNode (VN)	GPU cloud, hợp tác NVIDIA	—	Đối thủ nội địa trực tiếp

SLIDE 6 — Ma trận định vị

Định vị Dedicated Inference



Vị trí FPT: góc “**niche local dedicated**” — dedicated + data residency Việt Nam. Khoảng trống chưa đối thủ nào chiếm giữ mạnh.

SLIDE 7 — Pricing Benchmark (Dedicated GPU/giờ, 2026)

GPU	Range on-demand	Provider thấp	Hyperscaler cao
H100	\$1,99 - \$14,90	Vast \$1,60 · GMI \$2,00 · RunPod \$2,89	AWS ~\$6,16
H200	\$1,99 - \$13,78	GMI \$2,60 · Jarvislabs \$3,99	AWS \$7,91 · Azure \$10,60
B200	\$3,20 - \$16,11	Runcrate \$3,20 · Lambda \$3,49	AWS \$14,24 · GCP \$16,11
A30	Entry-level (thấp hơn H100 đáng kể)	—	—

Insights: - **Neo-cloud** định giá thấp hơn hyperscaler **40-60%** — FPT nên theo nhóm này - **Reserved/dedicated** rẻ hơn on-demand khi cam kết dài hạn - **A30** = entry-point giá rẻ thu hút SME, upsell lên H100/H200/B300

SLIDE 8 — Phân khúc khách hàng & SWOT

Phân khúc mục tiêu:

Phân khúc	Nhu cầu	Ưu tiên
Enterprise VN (ngân hàng, tài chính, y tế, chính phủ)	Data residency, compliance, SLA	Cao
Startup GenAI VN	Chi phí thấp, không rate limits	Cao
Enterprise Nhật/Hàn	Dedicated, latency thấp	Trung
ISV / Agency	Tích hợp API, white-label	Trung

SWOT tóm tắt: - **Strengths:** Hạ tầng tự chủ VN · quan hệ NVIDIA · data residency · model tiếng Việt - **Weaknesses:** Brand toàn cầu thấp · model catalog hẹp · vận hành GPU mới - **Opportunities:** Thị trường \$117,8 tỷ · serverless→dedicated migration · chiến lược AI quốc gia - **Threats:** Đối thủ giàu funding · GreenNode/Viettel · biến động giá GPU

SLIDE 9 – Chiến lược GTM

Định vị: “FPT DDI — Deploy an AI model running on dedicated, reserved GPUs. Always on, no shared capacity, and no rate limits. Better suited for serious traffic than serverless.”

Ba trụ cột khác biệt: 1. **Dedicated & Always-on** — tài nguyên GPU riêng, không shared capacity, không rate limits 2. **Data residency Việt Nam** — tuân thủ Nghị định 13/2023 3. **Tiếng Việt & địa phương** — model FPT.AI, hỗ trợ bản địa, latency thấp

Chiến lược giá:

GPU	Định giá đề xuất	So với thị trường
A30	Entry-point rẻ, thu hút SME	Cạnh tranh nhất
H100	Ngang neo-cloud (\$2-3/giờ)	Cạnh tranh
H200	Ngang GMI/Jarvislabs (\$2,6-4/giờ)	Cạnh tranh
B300	Premium, reserved	Cao hơn, dành enterprise

Kênh: Sales enterprise FPT · NVIDIA ecosystem · Portal self-serve + free trial · Việt Nam → Nhật/Hàn

SLIDE 10 – Lộ trình (Roadmap)

Giai đoạn	Trọng tâm	KPI chính
Phase 1 — Foundation (0-6 tháng)	Ra mắt dedicated trên H100/A30, model catalog cốt lõi, API chuẩn, portal self-serve	≥20 model, ≥10 khách hàng pilot
Phase 2 — Scale (6-12 tháng)	Thêm H200/B300, SLA cam kết, BYOM, enterprise onboarding, data residency cert	≥50 model, ≥50 khách hàng, 99,9% uptime
Phase 3 — Expansion (12-24 tháng)	Mở rộng Nhật/Hàn, multi-region, fine-tuning platform	≥100 model, ≥200 khách hàng

KPI chính: Số model ≥20→50→100 · Khách hàng ≥10→50→200 · GPU utilization ≥60% · Uptime ≥99,9% · NPS ≥40, retention ≥90%

SLIDE 11 — Khuyến nghị

Must: 1. Định vị rõ “dedicated + always-on + data residency VN” 2. Cam kết “no shared capacity, no rate limits” trong SLA 3. Hoàn thiện model catalog (model tiếng Việt FPT làm điểm nhấn) 4. OpenAI-compatible API + SDK — chuẩn ngành, giảm chi phí chuyển đổi

Should: Pricing theo neo-cloud (thấp hơn hyperscaler 40-60%) · Portal self-serve + free trial · Tận dụng quan hệ NVIDIA · Enterprise compliance pack

Could: BYOM · Fine-tuning platform · Multi-region (Nhật, Hàn)

Won't: Không cạnh tranh giá rẻ nhất serverless commodity với DeepInfra — tập trung dedicated value

SLIDE 12 — Closing / Thank you

Cảm ơn!

FPT DDI — Dedicated Inference Always on · No shared capacity · No rate limits · Better suited for serious traffic

Next steps: Phê duyệt định vị · Chốt pricing · Khởi động Phase 1 (Foundation)

Liên hệ: Thuan Luu Thi (PO)

Ghi chú cho người dựng deck

- **Phong cách:** Consulting, FPT brand (navy #001a4d → #003087 → #0072CE, accent cam #F27123)
- **Logo:** FPT logo trên cover + góc trên phải mỗi slide
- **Mermaid:** Slide 4 (flowchart) & Slide 6 (quadrantChart) cần render thành hình
- **Font:** Hệ thống (system-ui / Noto Sans), cỡ tối thiểu 20px
- **Kích thước:** 1920×1080 mỗi slide, không scroll
- **Slide 8:** dùng layout 2 cột (phân khúc + SWOT)