

WORKSHOP · BEST PRACTICE · BUILDING WITH VIBEFLOW

CODE BY WORDS — LAUNCH BY VIBE.

FPT Dedicated Inference on GPU Containers

Hành trình SDLC: từ 1 câu yêu cầu đến sản phẩm chạy thật

MVP · DEDICATED INFERENCE

PLANNING → DESIGN → DEVELOPMENT → TESTING → DEPLOYMENT → LAUNCH

AGENDA

- **01** · Bối cảnh — sản phẩm thật DDI
- **02** · Cách làm — 6 pha SDLC x VibeFlow
- **03** · Hành trình — artifact thật từng pha
- **04** · Con số & bài học
- **05** · Demo live — preview & vòng screenshot

DDI — SẢN PHẨM THẬT, KHÔNG PHẢI DEMO

- **Always-on** — endpoint riêng, không ngủ
- **Reserved GPUs** — H100 dành riêng, không chia sẻ
- **No rate limits** — cho traffic nghiêm túc

Model Catalog Admin — chủ đề dissect hôm nay — chỉ là **một vòng lặp SDLC** trong chuỗi dài đã làm với VibeFlow.


FPT Dedicated Inference Console – My dedicated models		
ENDPOINTS 1	ACTIVE 1	
ENDPOINT	HARDWARE	STATUS
gemma-4-26b-a4b-it	GPU-H100-1	Running

ALWAYS-ON

RESERVED GPUS

NO RATE LIMITS

CÁCH LÀM — 6 PHA, 1 CUỘC HỘI THOẠI



Human-in-the-loop: VibeFlow đề xuất & thực thi — **con người quyết định** tại từng gate.

PLAN — BRD TỪ MỘT CÂU YÊU CẦU

“Tôi muốn dựng hệ thống admin để khai báo model catalog cho Dedicated Inference. Cho tôi 1 số option như feed từ HF về, tự khai báo bằng admin.”

VIBEFLOW (BA AGENT) TRẢ VỀ

BRD v1.1 · 13 FR · 4 phương án A-D

A: HF trực tiếp · B: mirror nội bộ · C: manual ·

D: hybrid ✓

5 CÂU HỎI MỞ → USER CHỐT

Nguồn HF hay mirror? · Máy cấp duyệt?

Model độc quyền? · Giá? · Auto-sync?

→ Chốt **phương án D — hybrid**: HF nguồn chính + manual + batch (Phase 2).

PLAN — 5 QUYẾT ĐỊNH SẢN PHẨM (LỜI USER)

MIRROR NỘI BỘ

“b” — pull weights về S3 nội,
deploy từ mirror, checksum
SHA-256

1 CẤP DUYỆT

Admin duyệt; quyền cấp theo
role

PROPRIETARY TÁCH RIÊNG

catalog_type: public /
proprietary

GIÁ TỰ KHAI BÁO

USD/GPU/h theo từng
hardware profile

AUTO-SYNC REVISION

Theo lịch, toggle từng entry

HF_MODEL_ID BẮT BUỘC

Kể cả model độc quyền: fpt-
internal/...

DESIGN — SRS + KHÁM PHÁ TÍCH HỢP THẬT

- SRS: 14 FR · 9 NFR · RTM · data dictionary
- User cung cấp **Postman collection** BFF portal
- Phân tích reuse / gap trước khi thiết kế

REUSE

catalog CRUD,
categories,
hardware_profiles

GAP → ADMIN LO

approval,
catalog_type,
mirror, sync, audit

Admin = **workflow orchestrator**,
publish idempotent sang BFF —
không chờ đội BFF.

DESIGN — PROTOTYPE · STORIES · KIẾN TRÚC

PROTOTYPE

7 màn hình M1-M7
role matrix · 10 edge cases
· UAT checklist

USER STORIES

19 US · 12 epics
AC dạng Given-When-Then

SYSTEM DESIGN

5 ADR · 17 endpoints · DB 4
bảng
topology deploy · security ·
monitoring

Quality gate: review “đủ điều kiện dev chưa?” → **Conditionally ready** · 4 blockers
B1-B4 · Sprint 0 gỡ — *review trước khi code.*

BUILD — DEV AGENT THỰC THI

DB

migration 015
4 bảng mc_* +
seed

BACKEND

6 module
store · hf ·
publish · mirror ·
routes · config

FRONTEND

SPA vanilla JS
7 màn hình,
theme khớp
console

DEPLOY

Caddy prod +
preview
route /admin ·
Helm sẵn

Reuse code hiện có (code graph): audit_log · byom processor (HF/S3) · keys RBAC
— không phát minh lại.

TEST — CHẠY THẬT, KHÔNG CHỈ VIẾT

36

e2e checks PASS

PG + Redis thật (podman) · RBAC ·
workflow · mirror · categories · audit · HF
fetch

BUG TÌM RA KHI CHẠY

FIX

esc() FE vô hiệu (entity
decode)

unicode
escape

server crash: biến ngoài
scope

sửa catch
block


SQL 3 placeholder trùng
\$1

đánh số riêng

test không idempotent

run suffix

DEPLOY — PREVIEW & LIVE FEEDBACK LOOP



- User mở browser → **chụp màn hình lỗi** → fix trong phút
- 404 /admin → handle_path · modal trống → CSS [hidden]
- Key viewer dính → tách storage riêng · verify trả role
- **Change request bằng hội thoại:** “tôi là admin nên được approve” → đổi rule, test lại 36/36

KẾT QUẢ — CON SỐ BIẾT NÓI

7

docs SDLC

14

FR · 9 NFR

19

user stories

7

màn hình

17

endpoints

4

bảng DB

36

e2e pass

8+

bug đã fix

BPR — AS-IS VS TO-BE VỚI VIBEFLOW

PHA	AS-IS (TRUYỀN THÔNG)	TO-BE (VIBEFLOW)
Yêu cầu	Hợp nhiều vòng, tài liệu phân tán	1 câu → BRD + options trong phiên
Thiết kế	Wireframe tay, chờ review	Prototype + stories + ADR liền mạch
Phát triển	Dev đọc spec, tự suy diễn	Dev agent bám đúng design, reuse code graph
Kiểm thử	Test sau code, bug muộn	e2e chạy thật mỗi vòng, bug ra ngay
Feedback	Email / ticket, vòng dài	Screenshot → fix trong phút

Một mạch hội thoại = một mạch SDLC. Không mất ngữ cảnh khi chuyển vai trò.

4 BÀI HỌC MANG VỀ

01 · CHỐT Ở GATE

Quyết định sản phẩm phải của con người — tại từng gate, đừng để trôi.

02 · TÍCH HỢP THẬT SỚM

Postman / URL thật vào cuộc → thiết kế không bay bổng.

03 · CHẠY ĐỂ TEST

Test không chạy thật = chưa test. Bug thật rẻ hơn bug prod.

04 · PREVIEW + SCREENSHOT

Vòng feedback nhanh nhất: user bấm, chụp, gửi — agent fix.

Áp dụng cho sản phẩm của bạn: bắt đầu bằng **một câu yêu cầu** — phần còn lại là kỷ luật SDLC.

VIBEFLOW IN ACTION · FPT DEDICATED INFERENCE

LAUNCH **BY VIBE.**

Q&A

vibeflow.fptconsulting.co.jp